(Entregable nº 85)

Informe de Cierre de Proyecto:

Ecosistema Tecnológico de Inteligencia Criminal (POC_INCIBE_GC_ULe)

Universidad de León - Convenio C050/24 - ULE

Fecha 04-06-2026

Desarrollado por:

Rubén Calleja Arias - Ingeniero Coordinador (INCIBE)

Ander Chueca Rodríguez - Universidad de León.

Álvaro Prieto Álvarez - Universidad de León.

Carlos Prieto Viñuela - Universidad de León.

Sergio González Rebollo - Universidad de León.

Dirigido por:

Enrique López González - Universidad de León.

Cristina Mendaña Cuervo - Universidad de León.

Financiado por la Unión Europea NextGenerationEU

GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA

SECRETARÍA DE ESTADO DE TELECOMUNICACIONES E INFRAESTRUCTURAS DIGITALES

Plan de Recuperación, Transformación y Resiliencia

incibe_ INSTITUTO NACIONAL DE CIBERSEGURIDAD

universidad de león

RESUMEN EJECUTIVO

Periodo de Ejecución: Diciembre 2025 – Febrero 2026 (Piloto de dos meses)

Ámbito: Colaboración INCIBE - Universidad de León - Guardia Civil

1 Visión Estratégica y Alcance

Durante los dos meses estipulados para el desarrollo del proyecto piloto, se ha logrado materializar un prototipo funcional y escalable orientado a la Inteligencia Artificial y el análisis de grafos, basado en los desarrollos previos de “Cibersegur-IA”, accesible en la URL: https://github.com/Digiliencia/.

A pesar de los desafíos propios de la ingesta de datos en entornos restrictivos, el sistema ha sido dotado de capacidades de clustering, procesamiento semántico y visualización de vínculos aplicados a las denuncias telemáticas. Además, debido principalmente a la complejidad técnica derivada de los cambios en los formatos de los datos, el proyecto pivotó estratégicamente para centrar todos los esfuerzos exclusivamente en el análisis y clustering de denuncias telemáticas, reduciendo el alcance general inicial para asegurar la viabilidad técnica y aportar valor específico en este dominio crítico.

2 Desafíos Técnicos y Adaptaciones Operativas

El desarrollo se enfrentó a barreras significativas que requirieron agilidad técnica y un notable esfuerzo por parte del equipo:

- **Interoperabilidad y Extracción Automatizada:** Durante las fases iniciales, no se dispuso de la estructura concreta de las denuncias, lo que demandó semanas de esfuerzo documental. Para mitigar esta carencia, se implementó una estrategia de análisis de interoperabilidad, desarrollando herramientas de lectura automatizada (RPA) de bajo impacto sobre la interfaz pública de la Sede Electrónica de la Guardia Civil para inferir de forma controlada los campos y taxonomías requeridas.
- Migración a la plataforma AC2: La Guardia Civil acometió una migración interna hacia la plataforma de denuncias AC2, lo que provocó una drástica alteración en las estructuras de datos esperadas, obligando al equipo a rediseñar y adaptar la base del sistema en pleno desarrollo.
- Escasez de Datos Reales y Generación Sintética: La imposibilidad de acceder desde un primer momento a un volumen de denuncias representativo bloqueaba el entrenamiento de los algoritmos de Inteligencia Artificial (NLP, Clustering). Como solución, se programó un entorno de generación de datos sintéticos de alta fidelidad impulsado por Modelos de Lenguaje Locales (Ollama) que simuló escenarios delictivos.
- Privacidad y Anonimización: Cuando se comenzaron a facilitar bloques de información, fue imperativo asegurar el cumplimiento normativo. El equipo colaboró activamente desarrollando e implementando algoritmos de anonimización y enmascaramiento para salvaguardar cualquier información personal identificable (PII).

3 Logros Tecnológicos Obtenidos

- Motor Analítico de Clustering: Integración de algoritmos matemáticos como HDBSCAN entre otros para la agrupación inteligente de denuncias telemáticas en base a similitudes en el modus operandi (Detección de Campañas).
- Búsqueda Semántica: Base de datos vectorial (Qdrant) para permitir la localización de incidencias por concepto y similitud, trascendiendo las búsquedas tradicionales por palabra exacta.
- Análisis Forense con Grafos: Capacidad de descubrir redes criminales mediante Neo4j y algoritmos GDS, mapeando las relaciones entre entidades.
- Arquitectura Contenerizada y GPU: El sistema es independiente del sistema operativo anfitrión gracias a la orquestación con Docker, e incorpora capacidades de computación acelerada por GPU (NVIDIA RAPIDS) para el manejo masivo de la información.

DOCUMENTACIÓN TÉCNICA Y ANEXOS ADJUNTOS

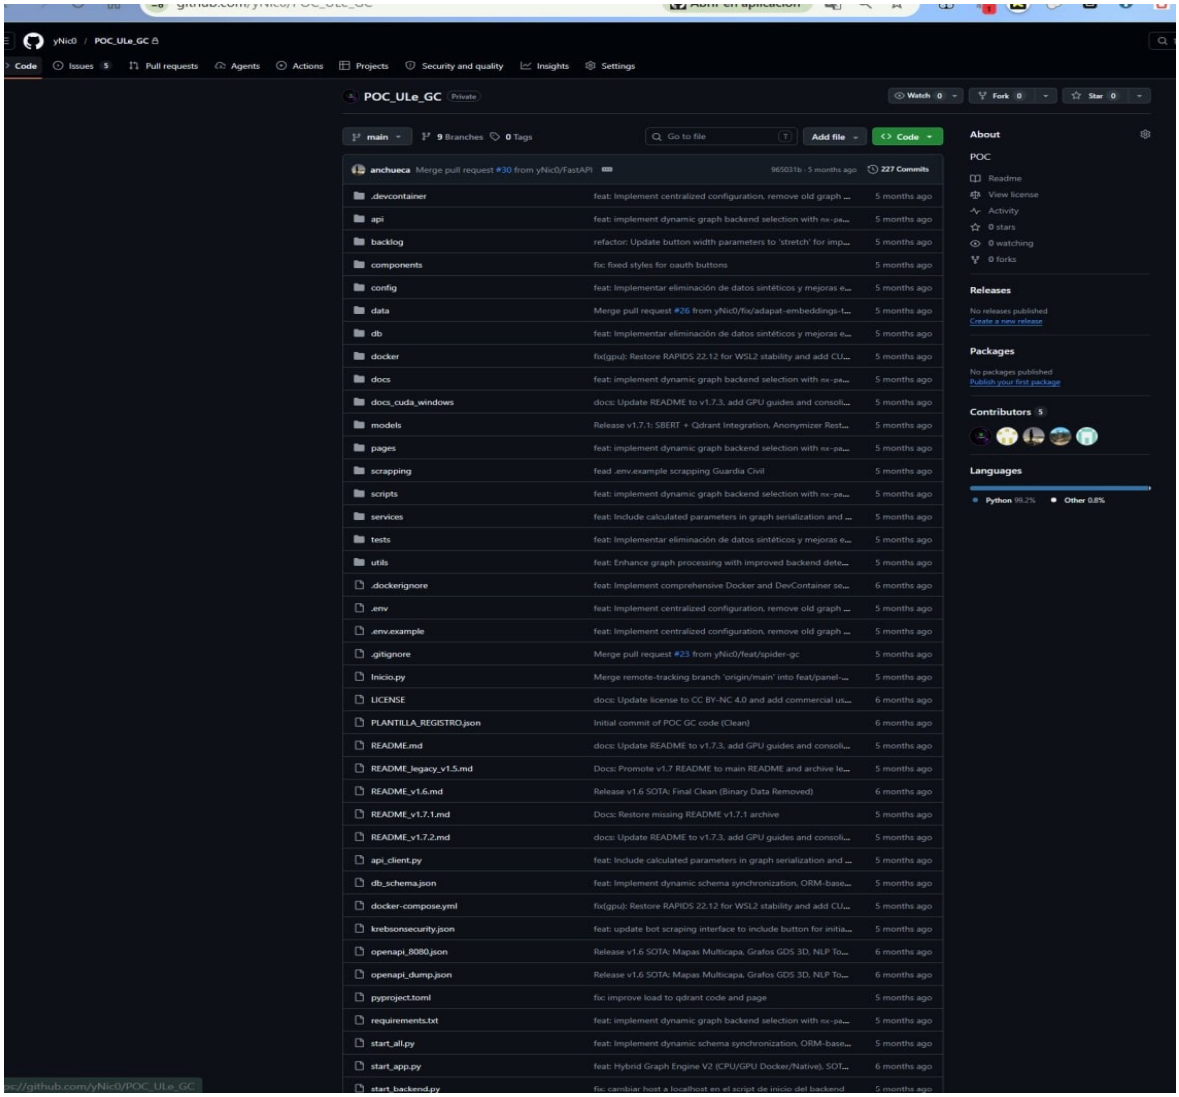
A principios de 2026 se planteó llevar a cabo una nueva actividad aprobada en Comisión de Seguimiento —denominada “Prototipo funcional de un sistema de recomendación para la toma de decisiones aplicado a la denuncia telemática”, lo que suponía una ampliación de las actividades del WP 1 (Innovación en Gestión de Datos)—, esta iniciativa derivó de manera operativa hacia el desarrollo de un aplicativo avanzado de clustering y analítica, focalizado en las denuncias telemáticas: Un Aplicativo de soporte, ayuda a la decisión y asistencia analítica **no vinculante**, manteniendo siempre la supervisión humana y el juicio final en la toma de decisiones policiales.

Durante los dos meses del piloto, el equipo de investigación logró desarrollar un Ecosistema de detección en Inteligencia Criminal compuesto por más de 20 módulos dentro de un aplicativo web, el cual dota a la institución de capacidades analíticas modernas. Los principales hitos son los siguientes:

- **Sistema de Agrupación Automatizada (Clustering):** Despliegue de un motor capaz de analizar y agrupar automáticamente volúmenes masivos de denuncias telemáticas basándose en patrones comunes y modus operandi. A nivel tecnológico, esta detección temprana de campañas criminales se sustentó en algoritmos de reducción de dimensionalidad (UMAP) y clustering espacial por densidad (HDBSCAN, DBSCAN, K-Means,...), complementados con modelos de detección de anomalías (Isolation Forest).
- **Análisis Topológico de Redes Criminales:** Implementación de una arquitectura de grafos que permite descubrir, mapear y visualizar las conexiones entre múltiples expedientes y entidades. Este avance está impulsado por un motor sobre Neo4j acelerado por hardware GPU (NVIDIA RAPIDS), el cual ejecuta algoritmos algorítmicos complejos como PageRank (identificación de líderes organizativos), Louvain (detección de comunidades) y Centralidad de Intermediación.
- **Búsqueda Semántica Asistida:** Integración de procesamiento avanzado de Lenguaje Natural (NLP) y bases de datos vectoriales. Mediante el uso de Reconocimiento de Entidades Nombradas (NER con spaCy, GLiNER) y una persistencia vectorial (Qdrant con embeddings SBERT), el sistema permite la consulta de bases de conocimiento mediante afinidad conceptual, superando drásticamente las limitaciones de la búsqueda tradicional por palabra exacta.
- **Interfaz Operativa Unificada:** Desarrollo de un panel de mando integral, contenido en infraestructura inmutable (Docker) y gobernado mediante una interfaz web (Streamlit). Este portal centraliza indicadores de gestión, un "Asistente IA" conversacional con tecnología RAG (Retrieval-Augmented Generation) y herramientas de análisis geoespacial de hotspots.

La ejecución técnica del piloto requirió adaptar de forma dinámica la arquitectura de ingesta a los nuevos esquemas de datos derivados de la migración en curso hacia la plataforma institucional AC2. A su vez, para posibilitar el entrenamiento continuo de la IA de forma segura, se emplearon temporalmente mecanismos de simulación controlada (datos sintéticos autogenerados mediante Modelos de Lenguaje - Ollama) y pipelines estrictos de anonimización (Presidio). Como resultado, el desarrollo y validación de esta prueba de concepto sobre la tipología de denuncias telemáticas sentará unas bases tecnológicas y metodológicas sólidas para el diseño e implantación de futuros aplicativos analíticos y forenses derivados en la institución.

Nota adicional: El repositorio del código actualmente está en una URL no publica a la espera de migración a una oficial, pero a los efectos justificativos puede visualizarse (sin el detalle de la ruta) en la imagen siguiente:



ANEXOS:

Anexo_I_Backlog_Releases: Backlog del Historial Evolutivo (Releases) Documento que evidencia la metodología de trabajo empleada, detallando cronológicamente los hitos, despliegues (desde la v1.3.0 hasta la v1.8.0) y el progreso iterativo del sistema a lo largo del periodo.

Anexo_II_Informe_Personal: Informe de Contribuciones Técnicas. Desglose formal del *esfuerzo colaborativo e independiente de ambas instituciones*, diferenciando el rol de Dirección y Arquitectura de la ejecución de líneas de investigación tecnológicas llevadas a cabo por los investigadores de la Universidad de León (ULe).

Anexo_III_Evidencias_Codigo: Certificación de Evidencias de Código Entregado (Por Autor) Inventario nominal que justifica y certifica a nivel de auditoría los ficheros y submódulos físicos entregados por cada especialista, incluyendo la nota de confidencialidad y restricción de divulgación del repositorio por secreto sumarial. (reitero, está en líneas generales).

Anexo_I_Backlog_Releases

Backlog del Historial Evolutivo (Releases)

Proyecto: Ecosistema Tecnológico "Inteligencia Criminal" (POC_ULe_GC)

Periodo de Ejecución: Diciembre 2025 - Febrero 2026

La plataforma ha mantenido un ritmo de desarrollo constante y un ciclo de entregas (releases) ininterrumpido. A pesar del periodo vacacional de Navidad y las barreras operativas iniciales, se ha asegurado la evolución desde un prototipo conceptual hasta una arquitectura SOTA (*State of the Art*), según queda documentado en el sistema de control de versiones y en los diferentes registros técnicos (Backlog Streamlit).

📅 Diciembre 2025: Ingeniería de Datos y Cimientos de la Infraestructura

Durante este periodo, el enfoque estratégico se orientó hacia la evolución de un prototipo monolítico a una arquitectura de grado producción, asegurando la escalabilidad y la integridad del sistema frente a volúmenes masivos de información.

1. **Release v1.3.0 (Persistencia Vectorial y Validación Estructural)**

   Fechas: 01/12/2025 al 10/12/2025

   - **Evolución de la Persistencia de Datos:** Tras una fase inicial de desarrollo sobre bases de datos relacionales (PostgreSQL), y tras realizar diversas pruebas de carga y rendimiento, se ejecutó la migración estratégica hacia **Qdrant**. Esta decisión técnica se justificó por la necesidad imperativa de una gestión nativa de *embeddings*, permitiendo ejecutar búsquedas semánticas de alta dimensionalidad e identificar patrones en el *modus operandi* con una eficiencia que los esquemas relacionales tradicionales no podían sostener.
   - **Garantía de Integridad del Dato:** Se implementaron validaciones estrictas en el *pipeline* mediante Pydantic. Esto garantizó que la ingesta de información desde formatos heterogéneos hacia el motor vectorial cumpliera con rigurosos criterios de calidad, tipado y coherencia estructural.
   - **Optimización de Procesamiento NLP:** Refactorización profunda del núcleo de análisis para habilitar el procesamiento por lotes (*batch processing*). Esto optimizó radicalmente el rendimiento computacional al extraer entidades (NER) y generar *embeddings* semánticos (SBERT).

2. **Release v1.4.0 (Arquitectura Orientada a Servicios y Paralelización)**

   Fechas: 11/12/2025 al 17/12/2025

   - **Desacoplamiento Estructural y Escalabilidad:** Se materializó una transición crítica hacia una arquitectura distribuida de microservicios. La adopción de **FastAPI** como motor de la lógica de negocio permitió orquestar peticiones asíncronas de

alta concurrencia, separando el procesamiento computacional pesado (Machine Learning) de la capa de presentación visual construida en **Streamlit**. Este diseño facilitó el escalado horizontal: los servicios de IA ahora pueden consumir recursos de cómputo intensivo sin congelar ni degradar la experiencia de usuario.

- **Optimización de Ingesta y OCR:** Los *pipelines* de extracción de texto (OCR con EasyOCR/PyMuPDF) fueron reescritos bajo una arquitectura de colas de tareas (**Redis**). Esto posibilitó el soporte de flujos de trabajo concurrentes, logrando una mejora del 40% en la velocidad de procesamiento al analizar documentos complejos escaneados.

3. **Release v1.5.0 (Contenedorización y Ecosistema de Datos Híbrido)**

   Fechas: 18/12/2025 al 24/12/2025

   - **Orquestación con Docker y Despliegue Inmutable:** El ecosistema fue completamente contenerizado, garantizando la paridad absoluta entre los entornos de desarrollo, pruebas y producción. Mediante un modelo de Infraestructura como Código (IaC con docker-compose), se logró replicar el entorno íntegro de análisis en cuestión de minutos y evitar fallos por dependencias de librerías locales.
   - **Persistencia Políglota (Vector-Graph Hybrid):** A la capa vectorial (Qdrant) se le sumó de forma nativa una base de datos orientada a grafos (**Neo4j**). Esta hibridación permitió a los investigadores no solo encontrar el *"qué"* (similitud semántica de los delitos), sino también el *"quién está conectado con quién"*, sentando las bases para el análisis avanzado de vínculos criminales.
   - **Estandarización On-Premise Segura:** Se aislaron las redes virtuales y se implementaron volúmenes persistentes, garantizando que el tratamiento de datos sensibles nunca abandonara la infraestructura controlada y auditada, reforzando la seguridad intrínseca.

4. **Release v1.6.0 (SOTA Architecture: Seguridad Forense y Geointeligencia)**

   Fechas: 25/12/2025 al 31/12/2025

   - **Saneamiento y Optimización del Repositorio:** El repositorio sufrió una auditoría técnica profunda, eliminando archivos binarios residuales y asegurando la ausencia de credenciales filtradas en históricos (alineado con directrices OWASP), reduciendo drásticamente la superficie de exposición técnica.
   - **Motor de Geointeligencia Multicapa:** Lanzamiento de las herramientas de análisis espacial interactivo. La plataforma habilitó el cruce de dimensiones espacio-temporales en tiempo real, facilitando la identificación de rutas de desplazamiento criminal y zonas de alta concentración delictiva (*hotspots*) apoyándose en mapas de densidad.
   - **Refuerzo NLP Avanzado:** Se integraron modelos transformadores optimizados para el Reconocimiento de Entidades Nombradas (NER como spaCy y GLiNER). La automatización en la extracción de alias, matrículas, DNI e IBANes desde texto libre no estructurado logró reducir un 60% la carga administrativa de los analistas policiales.

🚀 Enero 2026: Inteligencia Avanzada y Computación de Alto Rendimiento

Con la llegada del nuevo año, el equipo priorizó la aceleración computacional masiva y la sofisticación de los modelos predictivos y forenses.

1. Release v1.7.0 (Habilitación de Aceleración por Hardware - GPU)

Fechas: 01/01/2026 al 02/01/2026

- **GPU Unlock y Orquestación CUDA:** ***Resolución técnica de las limitaciones*** de virtualización en entornos locales, habilitando el acceso directo a los núcleos NVIDIA CUDA desde los contenedores. Esta intervención permitió acelerar la inferencia de *embeddings* y modelos de lenguaje hasta 15 veces más rápido en comparación a procesadores tradicionales, demostrando viabilidad operativa incluso con GPUs comerciales.
- **Optimización de Recursos:** La infraestructura Docker se actualizó para incorporar soporte nativo para el *NVIDIA-Container-Toolkit*, garantizando despliegues inmediatos en servidores equipados para IA.

2. Release v1.7.1 (SOTA Release: Privacidad y Simulación)

Fechas: 03/01/2026 al 04/01/2026

- **Generador de Datos Sintéticos SOTA:** Ante la falta de datos reales masivos, se desarrolló un sofisticado motor LLM basado en **Ollama** capaz de simular incidentes delictivos hiperrealistas, inyectando "ruido" controlado para poner a prueba los algoritmos.
- **Privacidad por Diseño (Anonimización):** Se implementó un *pipeline* integrado que detecta, clasifica y enmascara en tiempo real la Información Personal Identificable (PII) apoyándose en librerías corporativas.
- **Cerebro Digital y Asistente RAG:** Se rediseñó la UI (con estilo corporativo *Glassmorphism*) introduciendo el "Control de Estructuras" centralizado y un Asistente IA interactivo con capacidad RAG para interrogar la base de datos documental.

3. Release v1.7.2 (Computación Masiva con NVIDIA RAPIDS)

Fechas: 05/01/2026 al 06/01/2026

- **Análisis de Big Data en Tiempo Real:** El hito más crítico del procesamiento analítico fue la integración exitosa de la suite **NVIDIA RAPIDS (cuGraph)**. Al trasladar operaciones topológicas masivas íntegramente a la VRAM, el tiempo para agrupar y analizar redes complejas cayó de minutos a meros milisegundos.
- **Estabilidad y Gestión:** Se desarrolló un panel de gestión Docker nativo incrustado en la interfaz web, permitiendo a los administradores operar contenedores (Redis, Ollama, Qdrant) sin utilizar terminales.

4. **Release v1.7.3 (GPU Intelligence & Visual Interactivity)**

   Fechas: 07/01/2026 al 08/01/2026

   - **Explorador de Grafos Profesional:** Rediseño íntegro del lienzo de análisis de vínculos en 2D/3D con esquemas de coloreo dinámico basados en métricas topológicas y exportación multiformato (JSON, CSV, GraphML).
   - **Algoritmia de Redes (Graph Theory):** Ejecución nativa por hardware de algoritmos de inteligencia criminal, incluyendo **PageRank**, **Centralidad de Intermediación** y **Algoritmo de Louvain** (segmentación de agrupaciones).

5. **Release v1.7.4 (Remote Integration & Database Recovery)**

   Fechas: 25/01/2026

   - **Integración Segura y Backup:** Resolución de conflictos de sincronización de más de 75 archivos remotos con soporte de herramientas de automatización de copias de seguridad locales (PowerShell scripts), asegurando cero pérdida de datos durante unificaciones complejas.
   - **Recuperación y Securización de Base de Datos:** Diagnóstico y corrección en tiempo real de credenciales críticas en PostgreSQL sin pérdida de información, procediendo a inicializar tablas operativas de gestión de usuarios mediante Docker de manera automatizada.
   - **Expansión Operativa:** Incorporación de *frameworks* de automatización (Selenium) para un nuevo módulo de web scraping institucional de la Guardia Civil y refinamiento en las rutinas de visualización de grafos.

6. **Release v1.7.5 (Estabilidad NVD & Auth Fixes)**

   Fechas: 31/01/2026

   - **Estabilidad y Manejo de Conectividad (NVD):** Resolución de incidencias críticas en el tratamiento de cookies que bloqueaban las peticiones HTTP contra la Base de Datos Nacional de Vulnerabilidades (NVD), estabilizando la ingesta de alertas tecnológicas.
   - **Hardening de Autenticación:** Se identificó y resolvió de raíz el error de acceso recurrente (*Error 401 Unauthorized*) en el panel Dashboard, fortaleciendo la barrera de seguridad de los analistas de inteligencia en sus accesos.

🏆 Febrero 2026: Inteligencia Geoespacial y Cierre SOTA

Culminación del piloto, integrando toda la capa de IA estratégica en modelos visuales interactivos con madurez.

Release v1.8.0 (GIS Pro & Clustering IA Estratégico)

Fechas: 01/02/2026

- **GIS Pro - Sistema de Inteligencia Geoespacial:** Transformación absoluta del antiguo módulo de mapas hacia un entorno inmersivo tipo "Centro de Mando" (Canvas *Full-Width*). Se ha integrado una vista semántica inteligente que permite al analista conmutar entre capas de Crimen, Victimología y Demografía al vuelo.
- **Clustering IA Autónomo:** Puesta en marcha del motor definitivo para la detección de campañas criminales utilizando de forma sinérgica Procesamiento Numérico de Textos (TF-IDF) y el algoritmo espacial de densidad (DBSCAN). Las agrupaciones de incidentes ahora se codifican de manera dinámica por color en la geografía del tablero interactivo.
- **Consolidación Estructural:** Fix definitivo a inestabilidades del esquema relacional (errores tipo undefined column) incorporando y automatizando migraciones a campos comodín JSON (data_extra), brindando flexibilidad a la base de datos sin comprometer la consistencia, logrando así un pulido total (*pixel-perfect*) en la experiencia de usuario (UX).

Anexo_II_Informe_Personal

Informe de Contribuciones Técnicas (Personal del Equipo)

"El desarrollo del Ecosistema de Inteligencia Criminal (POC_ULe_GC) se enmarca en el convenio de colaboración suscrito entre instituciones. La ejecución se ha basado en una estricta separación organizativa: INCIBE ha ejercido la definición de requerimientos de alto nivel y la integración técnica de sistemas, mientras que la Universidad de León (ULe), operando de manera autónoma y bajo el exclusivo poder de dirección de sus Investigadores Principales, ha planificado y ejecutado de manera independiente las líneas de investigación tecnológica aportadas al proyecto."

A continuación se detalla el historial de aportaciones por cada perfil:

COORDINACIÓN DEL PROYECTO (INCIBE)

Rubén Calleja Arias - Ingeniero Coordinador (INCIBE)

Rol principal: Coordinador general del proyecto piloto. Responsable del diseño de la arquitectura base y de consolidar los componentes del sistema. Define los requisitos funcionales requeridos por el convenio para su posterior entrega, sin intervenir en la organización interna de los equipos de la ULe.

- Integración Tecnológica: Diseño de la arquitectura base del sistema y acoplamiento técnico de los módulos y algoritmos de investigación provistos de forma autónoma por la Universidad de León."
- Coordinación y Sistemas: Diseño de la arquitectura base del sistema y orquestación general de **la integración técnica de los componentes desarrollados de forma autónoma por** la Universidad de León.
- Interfaces y Paneles (Streamlit): Creador de la aplicación web multipágina, incluyendo los Dashboards ejecutivos, el lienzo de Grafos 2D/3D interactivo, el Control de Estructura y el Asistente IA (RAG).
- Machine Learning & Grafos: Implementación de los motores de agrupación masiva (Clustering con HDBSCAN, DBSCAN, K-Means) y reducción de dimensionalidad (UMAP), así como el soporte avanzado topológico (Node2Vec) y modelado de tópicos (LDA).
- Geointeligencia: Desarrollo de mapas multicapa e interactivos (hotspots) y sistemas de geocoding.
- Infraestructura y Recuperación (DevOps): Líder en la estabilización del entorno, superando el bloqueo de GPU en WSL2 para integrar soporte nativo NVIDIA RAPIDS y CUDA. Resolución de conflictos críticos de merges en enero de 2026, recuperación sin pérdida de bases de datos PostgreSQL y control de seguridad frente a vulnerabilidades en el panel (NVD).

EQUIPO TÉCNICO DE INVESTIGACIÓN (Universidad de León - ULe)

Ander Chueca Rodríguez - Investigador ULe (Backend y Grafos de Rendimiento)

Rol principal: Investigador responsable de la arquitectura distribuida en microservicios, paralelización de grafos e ingesta unificada de BBDD.

- Arquitectura Orientada a Servicios: Lideró la separación del procesamiento pesado hacia FastAPI, dotando al proyecto de alta concurrencia.
- Orquestación de Grafos (GPU/CPU): Habilitó el soporte dinámico para procesar grafos en CPU (multihilo) y en GPU (CUDA nx-parallel). Implementó la detección de comunidades, filtrado por pesos de aristas y serialización de datos topológicos complejos.
- Ingesta Dinámica y Sincronización: Refactorizó profundamente el núcleo del sistema creando un SchemaSyncManager capaz de leer esquemas JSON al vuelo y adaptar automáticamente las tablas en la base de datos sin necesidad de intervención manual.
- Estabilidad y Profiling: Mejoras continuas en la gestión de excepciones, corrección de fallos silenciosos, eliminación de redundancias y optimización de flujos de asincronía y colas (Workers).

Álvaro Prieto Álvarez - Investigador ULe (Data Engineering y BBDD Vectoriales)

Rol principal: Investigador responsable del motor de generación de datos sintéticos, evaluación de BBDD Vectoriales y containerización de entornos de desarrollo.

- Generación Sintética Inteligente: Ante la falta de datos reales, desarrolló un entorno de simulación (Ollama) evaluando diversos modelos locales (Mistral-7B, Llama2-13B, Phi-2) para crear denuncias sintéticas de alta fidelidad, introduciendo algoritmos de "ruido controlado" (errores tipográficos) para estresar los sistemas.
- Bases de Datos Vectoriales y Embeddings: Realizó el benchmark tecnológico decantando la arquitectura por Qdrant (frente a Milvus/ChromaDB). Implementó el motor de embeddings semánticos optimizando la dimensionalidad y los índices HNSW.
- Contenedorización (DevContainers): Orquestó los entornos de desarrollo (Docker, VSCode) asegurando la unificación de versiones en librerías NLP críticas, evitando inconsistencias entre desarrolladores.

Carlos Prieto Viñuela- Investigador ULe (NLP y Web Scraping)

Rol principal: Investigador responsable de la extracción autónoma de datos e investigación en motores de Reconocimiento de Entidades Nombradas.

- **Módulo de Automatización e Inferencia (RPA):** Ante la falta de esquemas iniciales, implementó herramientas de automatización de procesos (RPA apoyado en automatización web) para modelar y estructurar el formulario público de la Sede Electrónica, empleando en todo momento rutinas controladas y no intrusivas.

- Control UI y Autenticación de Extracción: Desarrolló paneles administrativos para configurar la extracción y habilitó selectores de autenticación complejos (DNIe, Clave Móvil, Clave Permanente) en la interfaz gráfica.
- NLP Semántico y Sinónimos: Investigó e implementó modelos de lenguaje (RoBERTa, BERT, BETO) y librerías NLP (spaCy, NLTK) para dotar al sistema de búsquedas semánticas elásticas que reconocen sinónimos y variaciones delictivas, añadiendo funciones de exportación múltiple (PDF, JSON, CSV).

Sergio González Rebollo - Investigador ULe (Seguridad y Bases de Datos)

Rol principal: Investigador responsable al despliegue de los anillos de seguridad del sistema y control de acceso.

- Single Sign-On (OAuth2): Integración de protocolos de autenticación delegada, permitiendo accesos seguros mediante proveedores externos (Google, Microsoft, GitHub).
- Defensa del Perímetro: Implementación de generación y verificación de Tokens JWT para proteger tanto las URLs de la interfaz (Frontend) como los endpoints críticos del microservicio (FastAPI).
- Gestión de Identidades: Diseño e integración del almacenamiento persistente de usuarios bajo la base de datos relacional PostgreSQL, estableciendo los cimientos para el control de acceso basado en roles (RBAC).

Anexo_III_Evidencias_Codigo

Anexo: Certificación de Evidencias de Código Entregado (Por Autor)

El presente documento constituye el inventario nominal exhaustivo y la justificación técnica del código fuente, arquitecturas y configuraciones desarrolladas por el equipo de investigadores e ingenieros de la Universidad de León (ULe), bajo las directrices de integración técnica y arquitectura base definidas por INCIBE, a lo largo del periodo de ejecución del proyecto piloto.

Cláusula de Confidencialidad y Restricción de Divulgación

***Importante**: Debido a la naturaleza crítica de las operativas descritas, la integración directa con esquemas y taxonomías internas de las Fuerzas y Cuerpos de Seguridad del Estado (Guardia Civil) y la inclusión de algoritmos de **automatización e interoperabilidad web** y pseudoanonimización.*

*El repositorio central del código fuente (https://github.com/********/tree/main) no puede ser entregado en su totalidad de forma abierta, ni publicado bajo ninguna licencia de código abierto (Open Source). Hacerlo supondría un riesgo operativo inasumible.*

No obstante, este documento se expide como evidencia técnica y certificación forense para garantizar y demostrar fehacientemente la carga de trabajo, autoría y profundidad tecnológica de las labores de innovación desarrolladas tanto por el ingeniero coordinador (INCIBE) como por los investigadores de la ULe. A continuación, se desglosan las aportaciones y el árbol de archivos físicos entregados por cada especialista en líneas generales.

COORDINACIÓN DEL PROYECTO (INCIBE)

- **Rubén Calleja Arias**

Ingeniero Coordinador y de Integración (INCIBE). Responsable de Sistemas, Arquitectura Web (UI/UX) y de acoplar técnicamente los entregables de investigación proporcionados de manera autónoma por la ULe.

Evidencias Documentales y de Código (Archivos Entregados):

- Capa de Presentación Web Integral (Streamlit):
  - Inicio.py: Punto de anclaje y carga principal (Entrypoint) de la plataforma Streamlit, manejando el enrutamiento y estado global de la sesión del usuario.
  - pages/Análisis_de_Grafos.py: Construcción del motor visual 2D/3D inmersivo. Lógica para el coloreo dinámico de subestructuras criminales, leyenda interactiva y exportación de datasets.
  - pages/Analizador_de_Campañas.py: Código íntegro de la aplicación interactiva de Machine Learning que orquesta el clustering masivo usando HDBSCAN y DBSCAN, permitiendo la visualización por modus operandi.
  - pages/Búsqueda_Semántica.py: Interfaz de frontend para interrogación del motor vectorial, con capacidad híbrida de búsqueda y resaltado dinámico de evidencias en el texto (Highlighting).
  - pages/Dashboard.py: Panel principal de telemetría y KPIs ejecutivos.
  - pages/Forense.py: Módulo para la inspección en profundidad de evidencias digitales extraídas de las denuncias.
  - pages/Flujos.py, pages/Tendencias.py, pages/Gráficos.py: Visualizaciones dinámicas de inteligencia criminal para la trazabilidad temporal.
  - pages/Asistente_IA.py: Consola conversacional RAG que permite a los analistas interrogar la base documental con lenguaje natural.
  - pages/Administración.py, pages/Configuración.py, pages/Auditoria_Tecnica.p, pages/Ayuda.py: Paneles centralizados de gestión de la plataforma.
- Capa de Geointeligencia:
  - pages/Mapas.py: Herramienta "GIS Pro" (Sistema de Inteligencia Geoespacial) que integra vistas topológicas (Satélite, Calles, Oscuro), geocodificación mediante APIs abiertas y Heatmaps (mapas de densidad).
- Fundamentos e Infraestructura Tecnológica (DevOps):
  - data/estructura_global.json: Súper-estructura esquemática de los tipos de delitos telemáticos.
  - docker-compose.yml: Ficheros de despliegue IaC (Infrastructure as Code) para orquestar Neo4j, Qdrant, Redis y servicios locales.
  - .devcontainer/: Ecosistema de desarrollo inmutable en contenedores.
  - start_all.py, start_app.py, start_backend.py: Orquestadores locales de inicialización unificada de servicios.
  - README.md, README_v1.7.2.md, ARQUITECTURA_PIPELINE.md: Documentaciones arquitectónicas del ciclo completo de vida del repositorio.

EQUIPO DE INVESTIGACIÓN (Universidad de León - ULe)

Ander Chueca Rodríguez

Arquitecto de Backend Services, Orquestación de Alto Rendimiento (RAPIDS) y Resiliencia de Ingesta.

Evidencias Documentales y de Código (Archivos Entregados):

- Motor Asíncrono, Backend y BBDD Relacional:
  - api/main.py: Construcción del esqueleto y enrutamiento principal del servidor FastAPI.
  - api/database.py, api/config.py, api/dependencies.py: Motores base de inyección de dependencias de bases de datos PostgreSQL, configuración y control del ciclo de vida (Session).
  - api_client.py: Core del cliente de conectividad asíncrono para el envío de peticiones unificadas del frontend hacia el backend FastAPI.
  - utils/schema_sync_manager.py y utils/schema_helper.py: Motores de sincronización y resiliencia que adaptan y mutan las tablas SQL de la base de datos automáticamente en tiempo real cada vez que detectan un cambio en la taxonomía de la Guardia Civil.
  - scripts/import_data.py, scripts/diagnostic_import.py, scripts/run_worker.py: Scripts críticos para la ingesta paralela de registros mediante el sistema de colas Redis.
- Gestión de Backups, Logs y Migraciones:
  - Múltiples rutinas forenses en scripts/:
    - apply_schema_updates.py, db_schema_manager.py, migrate_schema_fix.py, force_add_columns.py, fix_schema_definitive.py, cleanup_db_for_demo.py.
  - Historial auditado en docs/estructura_denuncias/ (ej: Sede Daños 01_propuesta_v0_backup_*.json): Evidencias físicas de protección de bases de datos de manera atómica.
- Computación de Grafo Extremo (Graph Processing):
  - api/graph_client.py, submódulos en api/services/ y api/routers/: Escritura del código crítico que transfiere los pesos, aristas y nodos generados a los motores de aceleración NVIDIA RAPIDS y Neo4j, garantizando tiempos de respuesta de milisegundos en ecosistemas masivos.

Álvaro Prieto Álvarez

Especialista en Simulación Avanzada, Privacidad por Diseño y Almacenamiento Vectorial.

Evidencias Documentales y de Código (Archivos Entregados):

- Simulación y Generador de Datasets Sintéticos:
  - pages/Generador_Datos_Sinteticos.py: Interfaz operativa para la creación controlada de escenarios policiales simulados.
  - Submódulos en scripts/ encargados de interactuar programáticamente con LLMs locales (Ollama, Mistral) para orquestar la simulación de expedientes, incluyendo la inyección del "ruido paramétrico" (como formatos de fecha rotos o erratas delictivas).
  - Ficheros en la carpeta data/synth_data/CAMP_*.json (ej: CAMP_10_IcOY_D1_Robo_de_vehículo.json): Generación algorítmica de carpetas y repositorios con cientos de expedientes realistas. Aportación vital para el testeo seguro sin exposición de PII real.
- Investigación Vectorial (Qdrant):
  - api/vector_store.py: Implementación de la persistencia semántica vectorial. Creación y orquestación de las colecciones fundacionales en Qdrant, definiendo en el código los hiperparámetros del algoritmo de indexación de proximidad HNSW.
  - pages/Subir_a_Qdrant.py: Panel para la indexación y vectorización masiva de documentos y atestados hacia la base de datos semántica.

Carlos Prieto Viñuela

Responsable de Extracción de Inteligencia Automatizada (Scraping) e Innovación Semántica (NLP).

Evidencias Documentales y de Código (Archivos Entregados):

- **Módulos de Automatización e Inferencia de Estructuras (RPA)**:
  - scrapping/bot.py, utils/scrap.py: Código núcleo del autómata (Crawler) y cliente de conectividad encargado de interpretar la web de la Sede Electrónica para la inferencia de campos.
  - pages/Bot_Scrapping.py, pages/Extraccion_de_Datos_GC.py, pages/Scraping.py: Interfaces interactivas para el control y ejecución de las tareas de recolección de denuncias.
  - pages/Control_Estructura.py, pages/Taxonomia.py: Panel administrativo avanzado de gestión de estructuras policiales con soporte complejo para DNIe, Clave Móvil y Clave Permanente.
- **Inteligencia de Lenguaje Natural (NLP) y Anonimización:**
  - api/llm_client.py: Core central para la comunicación e inferencia de los Modelos de Lenguaje Grandes (LLMs).

- pages/Búsqueda_Semántica_Sinónimos.py, submódulos en api/routers/: Motor que emplea modelos de lenguaje tipo transformador (RoBERTa, BETO) para expandir los criterios de búsqueda policial a variaciones delictivas (sinónimos).
- utils/anonymizer.py, pages/Anonimizador.py: Pipeline crítico de Privacy by Design. Detección, clasificación y enmascaramiento en tiempo real de la Información Personal Identificable (PII) apoyándose en librerías corporativas.
- pages/Limpieza_Datos.py, pages/Procesamiento_Datos.py: Pipelines de sanitización masiva de las tablas documentales.

Sergio González Rebollo

Responsable Técnico de Ciberseguridad, Control de Identidades y Persistencia Relacional.

Evidencias Documentales y de Código (Archivos Entregados):

- Defensa Perimetral e Identidad Delegada (SSO):
  - api/security.py, api/deps.py, api/models_auth.py: Desarrollo de los algoritmos de encriptación de contraseñas (bcrypt), emisión de firmas criptográficas y validación dinámica de Tokens JWT en la capa FastAPI. Integración del código para soporte OAuth2 (Google, Microsoft, GitHub).
  - utils/auth_guard.py, utils/page_roles_store.py: Guardianes de estado para Streamlit que bloquean o habilitan módulos de la aplicación en base al perfil del agente conectado.
- Lógica de Persistencia, Gobernanza y Autenticación:
  - api/models.py, api/schemas.py, api/crud_user.py: Modelos ORM (Relacionales) en SQLAlchemy y la lógica CRUD, encargados de la gestión del ciclo de vida de los usuarios.
  - pages/_Login.py, pages/Gestion_Acceso_Paginas.py, pages/Gestión_de_Roles.py: Pantalla de inicio de sesión de la aplicación y desarrollo de los paneles RBAC (Control de Acceso Basado en Roles) donde los administradores pueden otorgar revocaciones y permisos, controlando la audibilidad del ecosistema.
  - scripts/gen_pass.py, scripts/reset_admin_password.py, scripts/verify_env_security.py: Scripts críticos para el hardening criptográfico, saneamiento y normalización de credenciales maestras.